

Informe técnico — Las NewJeans

Hackathon 2026 · Universidad de los Andes

Integrantes: Adrian Velasquez · Laura Juliana Ferreira · Andres Botero

1. Arquitectura del sistema

Partimos de una observación: **lo difícil es encontrar la cita correcta; una vez recuperada, responder es casi trivial** y no requiere un decoder fuerte. El sistema es una cadena de etapas en la que cada una refina la evidencia de la anterior antes de llegar a un modelo de 8B que solo redacta:

1. **Recuperador** (src/retrieve/hybrid.py): consulta = pregunta (+ opciones en cerradas), expandida con alias normativos por reglas (query_expand.py, sin LLM). BM25 con stemming español top-100 u denso multilingual-e5-large top-100, fusión Reciprocal Rank Fusion (k=60) → 50 candidatos.
2. **Reordenador** (rerank.py): cross-encoder BAAI/bge-reranker-v2-m3 → top-6 al prompt. Su score (sigmoide) decide de forma determinista responder, reintentar con un pool ampliado o abstenerse (sufficiency.py, umbrales 0.10 / 0.02).
3. **Redactor**: Qwen3-8B, una sola llamada con salida JSON forzada por gramática GBNF por formato. citation_check.py espeja evaluate.citas_respaldadas(): si toda cita de la respuesta carece de respaldo en la evidencia, se abstiene en vez de entregar una norma inventada.
4. **Agente de citación** (src/generate/cite_builder.py, determinista, sin LLM): extrae con citations.extract las normas de los 4 primeros pasajes de evidencia y las agrega como "Fuentes en la evidencia" en referencia_legal (semi-abiertas) o justificacion (cerradas). Solo agrega un nombre si el extractor oficial lo vuelve a leer como la misma norma. Toda norma agregada está en la evidencia entregada: queda respaldada por construcción.

Peor caso: 2 recuperaciones + 1 generación por pregunta. La etapa 4 es una función pura de (salida del redactor, pasajes), reproducible byte a byte.

2. Selección de encoder y decoder

Componente	Modelo	Motivo	Alternativas medidas
Encoder	intfloat/multilingual-e5-large	Mismo encoder que el evaluador usa para RAGAS; recall@10 0.841	BAAI/bge-m3: 0.785
Decoder	Qwen3-8B GGUF Q4_K_M, llama-cpp-python 0.3.36 (CUDA)	Mejor de 6 decoders ≤8B en sample_50 (31.65/50 sin reranker)	Llama-3.1-8B 22.10, Mistral-7B 25.44, Qwen2.5-7B 28.20, Aya-Expanse-8B 29.52 (CC-BY-NC)
Reranker	BAAI/bge-reranker-v2-m3	recall@6 0.724 → 0.764; citación 0.50 → 0.63	Ajuste fino con 4 000 preguntas sintéticas: recall@3 cae 0.805 → 0.707, no adoptado

Inferencia: temperatura=0 (greedy), seed=0, n_ctx=8192, tope de tokens por formato (700 / 420 / 900), plantilla ChatML. Máquina: RTX 4090 (24 GB). Latencia en las 992 preguntas: **~7.9 s/pregunta** (~2.2 h, presupuesto 6 h).

3. Estrategia de recuperación y corpus

Corpus: 34 380 documentos / **106 237 fragmentos**, 100% trazables a su norma de origen. Códigos y leyes (secretariassenado.gov.co, reescrapeados completos, incluido el Estatuto Orgánico del Sistema Financiero) segmentados por artículo con el nombre de la norma como prefijo; relatoria de la Corte Constitucional y providencias de la Corte Suprema en ventanas de ~250 palabras. Índices exactos y reconstruibles: faiss.IndexFlatIP y bm25s (reconstrucción verificada idéntica byte a byte).

Cambio	recall@6 de normas de referencia
Híbrido RRF, pool 30/30	0.695
+ reranker	0.724
+ pool 100/100 → 50	0.764

Cambio	recall@6 de normas de referencia
+ corpus reescrapeado, BM25 con stemming, Estatuto Orgánico	0.833 (recall@10 0.878)

Probado y descartado (sin mejora medida): reformulación de consulta con el LLM, anteponer el tema, vectores extra para fragmentos largos, encabezados de artículo en el fragmento, bono a normas sobre providencias, penalización de normas derogadas.

4. Citación y abstención

El puntaje de citación compara normas (no artículos) contra el fundamento de referencia y penaliza $\times 2$ las citas sin respaldo en los 10 primeros pasajes. El diagnóstico mostró que **la recuperación ya encontraba la norma, pero el redactor no la citaba**: de 41 normas de referencia en el top-6, solo 29 aparecían en la respuesta. Pedirlo en el prompt subía la citación pero degradaba la respuesta que ve el juez (RAGAS 0.481 $\rightarrow$ 0.426). El agente de citación resuelve esto sin tocar el texto que se juzga.

Agente filtro con LLM (evaluado, no adoptado). Siguiendo la idea de una cadena de agentes que filtran la evidencia, Qwen3-8B eligió entre los 10-15 mejores pasajes del reranker los que sustentan la respuesta (filter_agent.py, salida forzada por gramática). Sus elegidos contenían la norma correcta en el 70% de los casos, frente al 75.6% del top-3 del reranker; de punta a punta 35.47 vs 37.03 /50. Con un decoder de 8B el cross-encoder ya cumple mejor ese papel.

La abstención depende solo de señales de recuperación, nunca de la autoevaluación del LLM (otra fuente de no-determinismo). Abstenerse vale 0.5; en sample_50 los únicos ítems con score < 0.10 fallaron.

5. Resultados sobre las preguntas de muestra (sample_50, sin RAGAS)

Componente	Viernes (17:00)	Sin agente de citación	Entrega	Posibles
Exactitud en cerradas	13.33 (10/15)	14.67 (11/15)	14.67 (11/15)	20
Calidad de citación	11.84	12.24	16.33	20
Abstención calibrada	6.74	7.21	8.14	10
Total automático sin RAGAS	31.91	34.12	39.14	50

RAGAS (answer_correctness, juez z-ai/glm-5.3-flash) medido el viernes: 0.481 (14.42/30, línea base 0.451). El agente de citación no modifica los campos que lee el juez.

Barrido del número de pasajes citados (k): k=2 $\rightarrow$ 37.16, k=4 $\rightarrow$ 37.57, k=6 $\rightarrow$ 37.97 /50 sobre la entrega del viernes, con 4.6 / 7.4 / 9.7 normas por respuesta. Elegimos k=4 como equilibrio entre puntaje y relleno.

Errores frecuentes. Las cerradas que fallan siempre son huecos de conocimiento o de corpus, no de razonamiento: el ítem 528 exige convertir 40 SMLMV a pesos (dato ausente del corpus), el 671 tiene como fundamento "Doctrina" y el 128 dependía del Estatuto Orgánico. Razonamiento previo, voto por permutación de opciones y Qwen3 en Q8 dieron 10/15 en todos los casos.

6. Limitaciones

- Muestra pequeña:** 50 ítems y 15 cerradas; ± 1 cerrada = ± 1.33 pts. Las decisiones finas se apoyaron también en recall de recuperación y en 4 000 preguntas sintéticas.
- Techo de recuperación:** el agente de citación solo cita lo que llega al top-4; si la norma no se recupera (recall@6 0.833), no se cita. No se aplica en open_ended, cuyos cuatro campos van al juez.
- Corpus:** la Corte Constitucional está solo como relatoría (sin texto íntegro); faltan leyes anteriores a 1992 que secretariassenado no publica y no hay doctrina. No hay señal de vigencia (norma vigente vs. derogada).
- Determinismo:** greedy a temperatura 0 es determinista para un binario y hardware fijos; la entrega y la verificación en vivo usan la misma máquina (RTX 4090, CUDA 13, mismo GGUF).