

Reporte de avance — Hackathon 2026

Equipo: Las NewJeans **Integrantes:** Adrian Velasquez, Andrés Botero, Laura Juliana Ferreira **Fecha de la medición:** 2026-10-02

1. Puntaje sobre las preguntas de muestra

`python scripts/evaluate.py --submission entrega.jsonl --split sample [--ragas]` — configuración Qwen3-8B + reranker + pool ampliado + prompt conciso, medida en Turing (GPU RTX 4090).

Componente	Puntos obtenidos	Puntos posibles
Exactitud en cerradas (11/15)	14.67	20
Calidad de citación (índice 0.551)	11.02	20
Abstención calibrada	6.51	10
Total automático sin RAGAS	32.20	50
Corrección texto libre (RAGAS, correctness 0.469)	14.08	30
Total automático con RAGAS	46.28	80

El sistema pasó de 26.6/50 (primera corrida, 1-oct) a 32.2/50 sin RAGAS al cambiar a Turing, comparar 6 decoders ≤8B (Qwen3-8B el mejor), añadir reranker y ampliar el pool de recuperación. RAGAS (juez glm-5.3-flash) medido: 0.469, por encima de la línea base de 0.451 (0.418 antes de acortar las respuestas). Con solo 15 cerradas, ±1 pregunta = ±1.3 pts.

2. Estado del corpus

Métrica	Valor
Documentos incorporados	34 379
Fragmentos indexados	99 067 (100 % trazables a su norma; sin fuga del banco)
Áreas del banco con cobertura	las 10; recall de normas de referencia en top-10: laboral, familia, penal, mercados, civil, tributario 1.00; constitucional 0.80; comercial 0.75; procesal 0.70
Áreas del banco sin cobertura / débiles	ninguna sin cobertura; débil: administrativo (recall 0.40). Huecos: texto íntegro de providencias de la C. Constitucional (solo relatoría), doctrina, Estatuto Orgánico del Sistema Financiero (26 art.), CCA pre-2011

Fuentes consultadas: Secretaría del Senado (Constitución, códigos, leyes, decretos, actos legislativos; 2 627 docs); relatoría de la Corte Constitucional (31 413 providencias, metadatos/resúmenes); providencias de la Corte Suprema (339 docs, troceadas por el equipo).

3. Arquitectura actual

Componente	Elección
Encoder	intfloat/multilingual-e5-large (denso, 1024 d, FAISS IndexFlatIP) + BM25
Decoder	Qwen3-8B Q4_K_M (llama-cpp-python, CUDA), temperatura 0, JSON forzado por gramática GBNF
Estrategia de recuperación	Híbrida BM25 (top-100) U denso (top-100) → fusión RRF (50) → reranker bge-reranker-v2-m3 → top-6 al prompt; reintento ampliado selectivo
Segmentación del corpus	Por artículo (códigos/leyes); ventanas de ~250 palabras con solapamiento (jurisprudencia)
Mecanismo de abstención	Umbral determinista sobre el score del reranker (0.10 / 0.02), sin autoevaluación del LLM; descarta citas sin respaldo

4. Riesgos identificados

- Divergencia CUDA vs Metal.** Con temperatura 0 las salidas pueden diferir entre GPU y Mac (medido: Llama 22.1 en Turing vs 26.5 en Mac). Mitigación: la verificación en vivo se hará en Turing (confirmado), que es la máquina canónica con la que se genera `submissions.jsonl`; determinismo verificado allí (0 divergencias); el Mac queda solo como chequeo cruzado auxiliar.
- Brecha frente a la línea base en cerradas** (0.73 vs 0.905; RAGAS ya 0.469 vs 0.451). Mitigación: mejor razonamiento en cerradas (decoder de mayor precisión, razonamiento previo), mejor recuperación en áreas débiles.
- Huecos de cobertura** (administrativo, procesal; sin texto íntegro de sentencias; sin señal de norma vigente/derogada). Mitigación: ampliar fuentes si hay tiempo y priorizar vigencia.
- Ruido de medición** (solo 50 ítems, presupuesto limitado de RAGAS). Mitigación: proxies gratuitos (recall, similitud) y RAGAS solo en finalistas.
- Latencia:** 7.6 s/ítem → 2.1 h estimadas para 992 (presupuesto 6 h); margen amplio.